# Architectures for big data

## Francesco Tomaselli

## 2 febbraio 2021

## Indice

1	Arc	hitetture 2	
	1.1	Introduzione	
	1.2	Motivazioni	
	1.3	CDC e Datalake	
	1.4	Jobs e scheduler	
2	Apache Hadoop 5		
	2.1	Elementi	
	2.2	Processo	
	2.3	HDFS	
3	Spark 6		
	3.1	Elementi	
	3.2	Funzionalità e caratteristiche	
	3.3	Processo	
	3.4	Spark to SQL	
4	Delta Lake		
	4.1	Transazionalità	
	4.2	Transaction log e shipping	
	4.3	Delta Lake	
5	Docker 11		
	5.1	Componenti	
	5.2	Sintassi	
	5.3	Processo	
6	Ser	vice-oriented architecture 12	
-	6.1	Servizi	
	6.2	Modelli di comunicazione	

#### 1 Architetture

#### 1.1 Introduzione

Stile architetturale Uno stile architetturale definisce la lista di design elements utilizzabili, oltre alle relazioni che sussistono tra essi. Nel contesto di sviluppo software uno stile incapsula le scelte importanti prese dagli architetti e ne coordina le interazioni. Esistono due problemi, erosion e drift, il primo consiste nell'usare l'architettura impropriamente, il secondo si manifesta quanto un'architettura viene usata per scopi diversi da quelli originali.

**Elementi** Per quanto riguarda gli elementi di un architettura, essi si suddividono in:

- 1. Data elements: contengono informazione
- 2. Connecting elements: connettono diverse parti dell'architettura
- 3. Processing elements: trasformano i dati

Materiali Un materiale ha qualche peculiare caratteristica, è necessario scegliere materiali adatti agli scopi. Nel software, si parla di framework, linguaggi di programmazione, etc . . .

Point of views È cruciale avere diversi punti di vista nella presentazione di un architettura, poichè esitono più attori con punti di vista differenti. Ad ognuno interessano o meno alcuni dettagli o aspetti dell'architettura totale.

Un esempio potrebbe essere una vista ad alto livello data al cliente, e una molto specifica data allo sviluppatore. Si può pensare poi ad una vista riguardo alle spese, che molto probabilmente non importerà ad esempio al team di sviluppo.

**Astrazione** Per astrazione si intende l'individuare un pattern, nominarlo, definirlo, analizzarlo e trovare un modo di invocarlo tramite il suo nome, così da evitare errori.

L'idea di base è quella di omettere i giusti dettagli nel contesto opportuno, semplificando l'interpretazione del risultato.

#### 1.2 Motivazioni

Esistono vari motivi per cui si architetta un architettura software.

- 1. Framework per soddisfare richieste
- 2. Base tecnica per il design, ovvero, è la base per la definizione di un particolare design, che ha tra i suoi elementi un'architettura a supporto

- 3. Base per la stima dei costi di un sistema
- 4. Porta al riuso delle componenti
- 5. Porta alla centralizzazione dei dati
- 6. Aumenta produttività e sicurezza
- 7. Mitiga il rischio di lock-in

Vendor lock-in Condizione in cui un cliente dipende da un certo vendor. Tale dipendenza si manifesta se il costo di cambiare vendor è maggiore rispetto al tenerlo. Per esempio, deciso un cloud o un servizio, un'azienda potrebbe avere adattato il suo sviluppo a quel particolare ambiente di sviluppo. Un cambio di cloud porterebbe a costi di adattamento troppo importanti.

Esiste anche il knowledge lock-in, ovvero quando il costo di spiegare o impartire una conoscenza in qualcuno costa più di mantenere la persona attuale. Per proteggersi da vendor lock-in si può ricorrere ad *Adapter Pattern*.

**Design pattern** Un design pattern è la formalizzazione di una best practice per risolvere un problema comune. Ad esempio: singleton, SOA, REST, P2P, MapReduce . . .

#### 1.3 CDC e Datalake

**Datalake** L'idea di un Datalake è quella di avere un luogo in cui salvare dati strutturati, ottenuti da una certa sorgente in forma non strutturata. Su un datalake si salva solamente, non si elimina nulla, alla modifica di un dato si inserisce la sua versione modificata.

Tale approccio cambia il patter ETL, poichè, si effettua una Extract, e una Load, per salvare su datalake, in un secondo momento si trasformano i dati in base al contesto.

Change data capture L'idea del CDC è quella di salvare solo i dati che sono nuovi o aggiornati dall'ultima raccolta dati. Ad esempio, nella raccola giornaliera di una tabella SQL, è possibile, invece che salvare più volte la tabella intera, salvare solo le tuple nuove o modificate, riducendo di molto lo storage utilizzato e il costo di computazione seguente.

Esistono vari modi di implementare CDC:

- *Invasive database side*: timestamp su righe, numero di versione, indicatore di stato, trigger su tabelle
- Invasive application side: si basa su eventi, un'applicazione deve mandare informazioni sullo stato al cdc
- *CPU database*: si confrontano i log del database, oppure utilizzando log shipping, tipicamente coinvolto nel backup automatico

**Diff and Where** Si differenziano due tipi di tabelle, log e registry table. Nella prima esiste un chronoattribute, utilizzabile per ottenere i dati aggiornati tramite query, nella seconda si applica un approccio basato su hash per capire se le tuple sono state modificate dall'ultima volta.

Move and rename L'approccio consiste nel garantire transazionalità di un CDC. È necessario quindi rendere possibile un eventuale rollback, e non lasciare mai il datalake in uno stato inconsistente. L'idea è scrivere i file in formato tmp e rinominarli al termine del job cdc. All'iterazione successiva si effettua rollback dei file tmp.

Adapter pattern Per evitare vendor lock-in, si utilizzando classi wrapper per evitare di dipendere strettamente da metodi definiti da un vendor. Un esempio può essere un source o destination adapter, che espongono metodi read e write, implementati a seconda del contesto.

#### 1.4 Jobs e scheduler

Job Un job è un elemento atomico che identifica una sequenza di passi o task da compiere. Può essere lanciato interattivamente o schedulato. Si identifica con un singolo processo.

Un job è caratterizzato da un id, un nome e uno stato, può essere poi

- 1. Finito: possono completare, essere terminati o fallire
- 2. Online: possono essere solo interrotti quando terminano

Scheduler Governa l'esecuzione dei job, può essere basato sul tempo o su eventi. Può decidere a quale processore o server (sistema distribuito) mandare un certo job, scegliendo tra quelli liberi.

Job queue Coda dei job che sono da eseguire, esiste un concetto di priorità, riconducibile alle classiche priorità dei processi nei sistemi operativi.

Job impersonation Un thread che esegue un job può impersonare un determinato client. Ad esempio, dopo un login, un thread può agire impersonando l'utente loggato, in modo che il server possa rispondere nel modo opportuno.

**Concurrency** Due job possono essere sequenziali o concorrenti.

### 2 Apache Hadoop

Apache Hadoop è un framework open source. L'idea è quella di aumentare l'affidabilità di un sistema, basandosi sul fatto che l'hardware puo fallire. Ha tre componenti: storage, resource management e computazione parallela.

#### 2.1 Elementi

Job Tracker Servizio che decide dove una task deve essere eseguita.

Task Tracker Nodo che accetta la task data da un job tracker. Espone slot che possono eseguire task parallele, infatti, all'arrivo di una nuova task, uno slot libero viene utilizzato per eseguire una JVM. Manda segnali di heartbeat.

Name node Contiene informazioni su dove i dati sono scritti. Mantiene quindi una lista di risorse e i relativi nodi che le contengono. Rappresenta un sigle point of failure per Hadoop. Esiste un backup name node.

Data node Nodo che contiene i dati effettivi.

Master e worker node Un nodo master è composto da un job tracker, un task tracker, un data node e un name node. Mentre un nodo worker è composto da data node e task tracker.

#### 2.2 Processo

Moving computation is cheaper than moving data

Un'applicazione manda un job asincono al job tracker, aspettando in polling. Il job tracker cerca i dati nel name node e sceglie i task tracker più vicini con slot disponibili.

Successivamente il job tracker manda i job ai task tracker, e ne monitora lo stato attraverso i segnali di heartbeat. Nel caso di fallimento il job tracker può scegliere di aggiungere il task tracker a una blacklist.

Confronto costi Bisogna tenere presente che in un contesto come quello di Hadoop risulta più economico muovere la computazione piuttosto che i dati. Bisogna quindi scegliere i task tracer in modo opportuno, tenendoli vicini ai data node interessati, piuttosto che muovere i dati in sè ed eseguire le operazioni.

#### 2.3 HDFS

HDFS è uno storage distribuito pensato per essere utilizzato su macchine poco performanti.

Un HDFS ha un architettura master/slave, dove esiste un name node per N data node. Il primo esegue operazioni sul file system, mentre i secondi si occupano di servire le richieste del primo e di gestire cancellazione, creazione e replica dei file.

Data node I file sono suddivisi in blocchi, le scritture non sono concorrenti sullo stesso blocco. Mandano segnali di heartbeat al name node.

Replicazione dei dati Si possono seguire varie strade per la replicazione dei dati in HDFS, ma bisogna essere rake aware, ovvero, bisogna replicare elementi dello stesso data node nello stesso posto, in modo da rendere più semplice la gestione di richieste multiple in caso di fallimento di un data node.

Un approccio è quello di replicare l'intero rack, diventa molto costoso perchè si sta scrivendo su rack differenti. Un'altro è quello di replicare 3 volte, una volta sul nodo che esegue la task, e altre due su due nodi di un rack differente. Le performance aumentano, essendoci 2 rack invece che possibilmente di piu

Quorum Journal Manager I data node sono affidabili, viste le tecniche di replicazione, per estendere ai name node, essi potrebbero essere multipli, uno attivo e gli altri in standby. I data node manderebbero il battito a tutti questi nodi. Al fallimento del name node attivo, esso sarebbe rimpiazzato da un altro nodo.

## 3 Spark

#### 3.1 Elementi

Resilient Distributed Dataset È un dataset distribuito in memoria su cui si possono effettuare operazioni in parallelo. Si può ottenere da un HDFS, oppure parallelizzando qualsiasi oggetto. L'idea è quella di distrubuire gli elementi tramite una funzione di hash tra i nodi che offrono computazione, tale distribuzione può essere forzata con un *repartition*. L'operazione è necessaria poichè ci si potrebbe trovare in casi dove un nodo ha molti più elementi degli altri, oppure per raggruppare meglio le chiavi in seguito a una join.

**Driver** Processo responsabile dell'esecuzione di Spark, divide l'applicazione in task piccole computabili dai nodi worker, che eseguiranno. Racchiude lo SparkContext, che permette di utilizzare Spark, e i metadati per

l'RDD.

Master È un nodo che contiene il driver, si occupa di orchestrare il lavoro tra i nodi worker, e ne monitora lo stato. Può avere un nodo di backup pronto in caso di fallimento.

**Spark Context** È il core di Spark, permette al driver di utilizzare il cluster. È singleton e manda segnali di heartbit agli executor per monitorarne lo stato.

Worker Nodo che si occupa della computazione, contiene molti executors.

**Executors** Sono quelli che effettuano le computazioni vere e proprie. Hanno un id, ed è garantito il backup se falliscono.

#### 3.2 Funzionalità e caratteristiche

**Pigrizia** Spark è pigro, non computa il risultato subito ma solo quando serve. È possibile quindi che un errore si verifichi solo all'esecuzione di una particolare riga dell'RDD.

Map e reduce Spark offre alcune funzioni di map e reduce. La prima permette di applicare una funzione ad ogni entry dell'RDD, mentre la seconda permette di eseguire riduzioni. Le seconde devono essere commutative, poichè non è garantito l'ordine con cui si eseguono le operazioni.

DAG Scheduler Ogni qualvolta che si effettua un'operazione su un RDD non si sta facendo altro che aggiugnere una task al DAG Scheduler. Il suo compito è quello ti trasformare un execution plan logico in uno fisico, in modo da effettuare la computazione vera e propria. Ogni passo del DAG Scheduler è chiamato Stage.

**Task Scheduler** Uno stage su un sottoinsieme di righe è chiamata Task. Una Task è lanciata dal Task Scheduler ed eseguita da uno Worker attraverso il Cluster manager. Il numero di Task è proporzionale al numero di partizioni considerate nell'RDD.

Shared Variables All'esecuzione di una map o reduce, Spark distribuisce una copia delle variabili delle funzioni tra tutte le righe. Questo comportamento può portare a problemi, nel caso di variabili molto pesanti. Si introducono le shared variables, che possono essere:

- Broadcast variables: read-only, per esempio, dizionario condiviso in memoria su cui fare lookup
- Accumulators: write-only

#### 3.3 Processo

Definiti elementi e caratteristiche di Spark l'esecuzione puo essere riassunta in questi passi:

- 1. Submit di un'applicazione utilizzando spark-submit utility
- 2. Allocazione risorse necessarie dal Resource Manager
- 3. Application master si registra al Resource Manager
- 4. Spark driver manda il codice all'Application Master, convertendo il codice in un DAG
- 5. Il Driver negozia con il Cluster Manager sulle risorse, e si creano gli Stage del DAG Scheduler
- 6. Gli Executors sono istanziati dagli Worker
- 7. Il driver tiene traccia dello stato degli Executors e manda le task al Cluster manager in base alla distribuzione dei dati
- 8. L'application Master crea una Container configuration per il Node Manager
- 9. È creato il primo RDD
- 10. Durante l'esecuzione il driver parla con l'Applicatin Master per monitorare lo stato, al termine si rilasciano le risorse

#### 3.4 Spark to SQL

La scrittura di dati da Spark a un database SQL potrebbe risultare critica e rallentare di molto il sistema. Infatti, la presenza di molti worker che tentano di scrivere in parallelo non aiuta, rendendo il database un collo di bottiglia.

**Table index** Struttura dati che aumenta le performance in lettura di una particolare tabella del database, non è necessario infatti effettuare una scan completa, ma si individua immediatamente la riga necessaria. In fase di inserimento, sono necessarie scritture addizionali per aggiornare l'indice.

**Problemi** Esistono problemi nella scrittura da Sparkl a SQL. In particolare, le operazioni di write occupano memoria, bisogna stabilire una connessione fisica e le tabelle indexed vanno lockate.

Struttura interna database Un database SQL è composto da data file e log file. I primi sono raggruppati in extents composti da pagine. Essi possono essere uniform, se ogni pagina è una data page, oppure mixed, se alcune pagine contengono informazioni sugli indici.

Esecuzione query All'arrivo di una query, questa viene convertita in un TDS utilizzando uno tra ODBC, OLEDB, SNAC, o SNI. Successivamente, SNI sul server decapsula il TDS e passa i comandi al query parser. Il query executor esegue la query e richiede agli access methods le pagine che sono coinvolte dalla query. Se si parla di query non select, interviene la logica di log e lock. La prima logga le operazioni, la seconda effettua il lock sulle pagine per garantire ACID properties.

**Tecniche di connessione** Per connettersi a un dataabase esistono tre metodi:

- 1. Connessione diretta: si apre una connessione con una socket, bisogna riaprirla ogni volta
- 2. Connection pooling: si mantengono connessioni aperte e vengono assegnate ai client che le richiedono
- 3. *Pool fragmentation*: si creano molti pool e ogni client può usare il proprio pool o no, differisce dal secondo perchè ogni client ha il proprio pool

Creazione e update di un indice Se una tabella risulta indicizzata, un inserimento deve tenere conto di alcune cose. Utilizzando ad esempio un B-tree+, i dati sono solo nelle foglie, le distanze tra le foglie non cambiano.

Per creare un indice i dati sono inizialmente ordinati, si sceglie una root e si aggiungono dati ad essa, quando questa è piena, si aggiunge un'altra root figlia e si procede.

Per aggiornare un indice, prima si cerca la posizione dove mettere l'informazione, se la pagina trovata è piena, si splitta la pagina ricorsivamente fino alla root.

Scrittura intermedia Data Lake Per risolvere il problema di scrittura in SQL da parte di worker multipli, si possono scrivere tutte le informazioni su un Data Lake e successivamente scriverle in bulk su SQL.

L'idea è quella di sfruttare il BCP, bulk copy program, per copiare tutte le righe nuove da datalake a SQL, e utilizzare MERGE per unirle alla vecchia tabella. La MERGE può definire logiche di unione.

L'approccio evita la creazione di dirty pages.

#### 4 Delta Lake

In un contesto big data esiste la sfida di rendere transazionali le operazioni. In particolare potrebbe essere necessario garantire consistenza e comunicazione tra i processi che stanno svolgendo particolari operazioni.

#### 4.1 Transazionalità

Per garantire transazionalità è necessario un controllo sulla concorrenza.

**Transazione** Sequenza di operazioni che soddifano le proprietà ACID.

Rollback Riportare il sistema allo stato precendete all'operazione eseguita.

**Proprietà ACID** Le proprietà che sono necessarie per garantire transazionalità sono:

- Atomicity: ogni operazione di una transazione è atomica
- Consistentcy: una transazione deve mantenere la consistenza del sistema
- *Isolation*: esecuzioni concorrenti portano allo stesso risultato di esecuzioni sequenziali
- Durability: una transazione non può essere ripristinata dopo un commit

#### 4.2 Transaction log e shipping

Per garantire consistenza e replicazione si possono usare transaction log e applicare transaction shipping.

**Transaction log** Storia delle operazioni eseguite da un database, possono essere utili per effettuare rollback in casi di errore di alcune transazioni che hanno lasciato il sistema in uno stato incosistente. Questi file possono diventare molto grandi

**Transaction shipping** I log possono essere mandati a un server per replicare lo stato del database e avere una copia esatta del sistema. È un'operazione molto pesante poichè bisogna scrivere tutte le operazioni che sono effettuate sulle tabelle.

#### 4.3 Delta Lake

L'idea è quella di garantire le ACID properties su HDFS, quindi su storage distribuiti.

**Apache Parquet** Parquet è un formato con cui mantenere le tabelle. Consiste nel mantenerle per colonna piuttosto che per riga, per velocizzare le operazioni di select.

Dividendo per colonna poi si può ottimizzare lo spazio richiesto per la codifica dei valori nella tabella. Infatti, i valori di una colonna sono più omogenei di quelli presenti in un'intera riga, quindi richiedono meno spazio e si possono comprimere. Parquet non è abbastanza per garantire transazionalità.

Write-ahead log Si mantengono quali oggetti fanno parte di una delta table, oltre ad aclune infomazioni statistiche quali massimo, minimo, count, etc ... Si scrivono poi le operazioni da fare sulle tabelle nel log, prima di eseguirle, oltre a quelle da applicare in caso di rollback.

Funzionalità Le funzionalità principali di un Delta Lake, che lo rendono propenso a un forte lock-in, sono:

- *Time travel*: esiste la possibilità di riportare lo stato dello storage a un determinato snapshot temporale.
- UPSERT, DELETE e MERGE: riscrivono in modo efficiente gli oggetti per applicare le operazioni richieste
- Straming efficiente: le informazioni sono scritte in modo veloce, poichè si suddividono in piccoli blocchi. I blocchi si uniscono dopo per velocizzare le letture
- Caching: i nodi del cluster possono cachare informazioni
- Schema evolution: si può cambiare lo schema delle tabelle continuando a leggere i vecchi file Parquet

#### 5 Docker

Docker è un set di platform as a service che offre la possibilità di racchiudere software in containers.

I container sono isolati uno dall'altro in termini di librerie e configurazioni, ma possono parlare attraverso alcuni metodi.

L'idea è quella di utilizzare *cgroups* del kernel Linux, che permette di limitare l'uso delle risorse da parte di un certo insieme di processi. In tal modo un container docker è meno impattante di una virtual machine.

#### 5.1 Componenti

**Docker file** Contiene tutti i comandi necessari per assemblare l'immagine. Utilizzando *Docker build* si compila il docker file eseguendo i comandi.

**Docker daemon** Si occupa di eseguire i comandi definiti nel docker file, ogni riga è eseguita e considerata come un singolo step. Modificando una certa riga, solo le righe successive ad essa verranno eseguite.

#### 5.2 Sintassi

I comandi possibili in un docker file sono

- FROM: inizio di ogni docker file, specifica la parent image dalla quale si sta effettuando la build. Può essere preceduto da alcuni parametri.
- RUN: esegue qualsiasi comando bash-like come step.
- *COPY*: copia un file dalla stessa cartella del docker file in una qualsiasi locazione all'interno del container.
- CMD: esecuzione di un'operazione alla startup di un container.
- ADD: come COPY, ma supporta URL
- $\bullet$  EXPOSE:usato per esporre un protocollo
- ENV: definizione di variabili locali
- USER: user che sta eseguendo un certo comando

#### 5.3 Processo

Il processo di creazione di un container docker è la seguente:

- 1. Creazione di un docker file con i comandi necessari
- 2. Esecuzione di docker build
- 3. Esecuzione di docker images per vedere tutte le immagini disponibili
- 4. Docker run -image- per eseguire il container
- 5. Docker ps per vedere i container attivi, -a per vederli tutti
- 6. Docker start/restart/stop/kill

 $\grave{\mathbf{E}}$  possibile orchestrare più containers con docker compose, tramite file di configurazione yml.

#### 6 Service-oriented architecture

L'idea di SOA è quella di fare da ponte tra il mondo IT e quello business, pensando un'architettura come qualcosa basato su servizi. Essi collaborano e possono potenzialmente creare applicazioni molto complesse.

#### Strati SOA Una SOA può essere vista a cinque strati:

- 1. Sistemi operativi: asset IT attuale
- 2. Componenti dei servizi: realizzano le funzionalità e garantisono la qualità dei servizi esposti, utilizzando le risorse del punto 1
- 3. Servizi: servizi deployati, seguono la definizione data in precedenza
- 4. *Processi di business*: layer che combina i servizi del livello sottostante per creare un sistema più complesso
- 5. Clienti: user che utilizza l'applicazione, oppure altra applicazione, etc.

#### 6.1 Servizi

Un servizio è una risorsa identificata da un nome che esegue un compito ripetitivo. È descritta da una service specification, senza scendere nei dettagli, ma rimanendo ad alto livello. Si puo vedere quindi come una black box. Ogni servizio offre le proprie funzionalità sotto forma di contratto.

#### Elementi Ogni servizio è costituito da:

- $\bullet$  Nome
- Versione
- Tipo di esecuzione: asincrona, sincrona, ...
- Metodo di logging: before, after, ...
- Message in: configurazione dei messaggi in ingresso
- Message out: configurazione dei messaggi in uscita
- Visibilità
- Eventuale binding con server objects, definiti da un application container e un integration implementation

**Server catalog** Catalogo di tutti i servizi disponibili, contiene una lista dei message in usati per configurare l'esecuzione dei servizi.

Service queue Lista delle esecuzioni dei servizi. Monitorandola si può controllare lo stato dei servizi in real time.

Enterprise service bus Sistema di comunicazione che permette ai servizi di comunicare con legacy systems. È utile per evitare la system-to-system integration ovvero integrazioni specifiche per ogni sistema. L'idea è quella di far comunicare ogni sistema con l'enterprise service bus, in modo da non occuparsene lato servizio, bensì lato legacy system.

Service broker Implementa il broker pattern, ha come compito il mandare i servizi al corretto application server, controllando la service queue. Si occupa anche di controllare lo stato dei message ins e messageo outs. Fornisce inoltre la descrizione di un servizio quando richiesta da un client, e controlla che un determinato clien abbia i requisiti di accesso richiesti.

#### 6.2 Modelli di comunicazione

Sincrono Il client compila il message in, l'ESB guida la richiesta, il service broker si occupa di inviare al server corretto, il quale esegue e risponde sul message out. L'esecuzione è corredata da uno stato e un log. I log sono mantenuti all'interno della Service Queue Table.

Asincrono Il client compila il message in, il service broker aggiunge il servizio da eseguire in coda. Quando il turno del servizio arriva, il broker troverà l'application server corretto. Esiste un ID, ritornato immediatamente, che il client può controllare per monitorare lo stato del servizio richiesto.

Streamed outbound file reference Quando l'output è molto grande, è infattibile scrivere sul message out. Si può estendere la logica asincrona in modo da scrivere l'output su un certo file. È possibile iniziare a consumare l'output durante la scrittura.

**Pub-sub service call-back** L'idea di un pub-sub è che un client possa iscriversi a un determinato topic e ricevere una notifica ad ogni evento. L'ESB può evitare al client la complessità del message bus, ad ogni nuovo evento un object id è passato al client.

Batch sync data process Un job CDC permette di estrarre dati incrementali da un legacy system, salvandole su un data lake. Un servizio gateway invia queste richieste al target system, es SQL.